

Estimation de la Criminalité en France (2024)

Projet SAE Sondages - Analyse comparative de plans de sondage

BARRACHINA Baptiste, ATHOUMANI Ycham

2026-01-04

Contents

1	Introduction	1
2	Présentation des données et Préparation	2
3	Simulations et Résultats	2
4	Sondage Aléatoire Simple (SAS)	2
4.1	Mise en place	2
4.2	Résultats	3
5	Stratification	3
6	Redressement par quotient	4
6.1	Mise en place	4
6.2	Résultat	4
7	Pondération (Horvitz-Thompson)	4
7.1	Mise en place	4
7.2	Résultat	5
7.3	Tableau Récapitulatif	5
7.4	Analyse Graphique	5
8	Conclusion	6
9	Bibliographie	6

1 Introduction

Les médias évoquent régulièrement un sentiment d'insécurité grandissant et une montée de la criminalité en France. Le rapport 2024 sur le « Vécu et ressenti en matière de sécurité » du SSMSI (Service statistique ministériel de la sécurité intérieure) confirme cette tendance. Il indique par exemple une augmentation du sentiment d'insécurité au domicile (+13 % en 2024 par rapport à 2023) ainsi que dans les transports en commun (+6 % en 2024 par rapport à 2023).

Dans ce rapport, nous allons analyser l'importance de la criminalité sur le territoire, comprendre sa répartition géographique et estimer son volume total. Nous nous concentrerons plus précisément sur l'indicateur des vols violents sans arme.

Pour ce faire, nous comparerons différentes stratégies de sondage (Sondage Aléatoire Simple, Stratification, Redressement et Pondération) afin d'estimer le total national sans avoir recours à un recensement complet,

en utilisant les données de l'année précédente comme variable auxiliaire.

Source des données : Les données utilisées sont issues des bases statistiques communale, départementale et régionale de la délinquance enregistrée par la police et la gendarmerie nationales, disponibles sur data.gouv.fr.

2 Présentation des données et Préparation

Les données proviennent de *data.gouv.fr*. Nous notons : y_k : Le nombre de vols en 2024 (variable d'intérêt).
 x_k : Le nombre de vols en 2023 (variable auxiliaire connue).

3 Simulations et Résultats

La population totale est de $N = 28899$ communes. Le vrai total à estimer est **54 576** faits constatés.

La corrélation entre 2023 et 2024 est de **0.9951**, ce qui justifie l'utilisation de méthodes basées sur la variable auxiliaire.

Nous fixons un taux de sondage de **20%**, ce qui nous donne une taille d'échantillon de $n = 136$.

4 Sondage Aléatoire Simple (SAS)

4.1 Mise en place

Le Sondage Aléatoire Simple est l'approche la plus simple et naïve, car elle consiste à tirer au sort, au hasard, n communes au sein de la population de $N = 28899$ communes recensées dans le fichier, toutes avec la même probabilité.

On peut d'abord s'interroger sur la taille de l'échantillon n qu'il faut choisir pour obtenir une estimation raisonnable. Nous avons fixé précédemment un taux de sondage de 20%, ce qui nous donne une taille d'échantillon de $n = 136$.

Dans le cas du SAS, on tire donc au sort un échantillon s de nos n communes, puis on en déduit une estimation de la criminalité globale comme suit :

$$\hat{T}_{SAS}(s) = \frac{N}{n} \sum_{k \in s} y_k$$

où y_k représente le nombre de vols violents sans arme de la commune k en 2024.

Grâce aux résultats du cours, nous sommes même capables de fournir un intervalle de confiance de niveau $1 - \alpha$ (avec $\alpha = 5\%$) pour le total T . En utilisant la dispersion de l'année précédente (S_{2023}^2) comme approximation de la variance de la population, l'intervalle est donné par :

$$I_{1-\alpha}^{SAS}(s) = \left[\hat{T}_{SAS}(s) \pm \sqrt{N^2 \frac{N-n}{nN} S_{2023}^2} \times \Phi^{-1} \left(1 - \frac{\alpha}{2} \right) \right]$$

On rappelle que S_{2023}^2 est la variance calculée sur l'année 2023 (l'année précédente). Comme N , n et S_{2023}^2 sont connus, le calcul de cet intervalle est très simple en pratique. On propose donc de l'implémenter à chaque estimation du total T des vols en 2024.

À titre indicatif, la variance observée S^2 en 2023 est de **4 313.03**.

Cela nous donne une marge d'erreur théorique (basée sur 2023) de +/- **318 221** vols.

4.2 Résultats

On propose de répéter le sondage 1 000 fois, c'est-à-dire d'estimer 1 000 fois le nombre total de vols violents sans arme en 2024 à l'aide du SAS construit dans le paragraphe précédent.

Nous obtenons une valeur empirique moyenne pour notre estimateur $\hat{T}_{SAS}$ de **45 381** faits, relativement proche de la vraie valeur de $T = \mathbf{54\ 576}$ faits enregistrée en 2024.

La vraie satisfaction est également que **48.7%** du temps, la valeur théorique T appartient à l'intervalle de confiance de niveau 95%, ce qui confirme que notre approche est bonne.

De même, le quantile de niveau 0.95 de l'écart entre notre estimateur $\hat{T}_{SAS}$ et T est de **96 931** faits.

Ces éléments confirment que notre approche est applicable. On remarque en revanche qu'une erreur de **96 931** faits est assez énorme, et que l'on souhaite réduire au maximum cette erreur. L'affinement de notre sondage par une stratification peut éventuellement être une solution.

5 Stratification

Comme renseignement supplémentaire aux noms des communes (ainsi que leur criminalité en 2023), on dispose du code géographique de chaque commune. On peut alors se demander si stratifier le sondage par zone géographique peut améliorer la qualité de l'estimation.

On peut en effet légitimement penser que certaines grandes zones urbaines (comme l'Île-de-France, code 7) sont plus sujettes aux vols violents et présentent une plus grande variabilité que des zones plus rurales. Si elles sont sous-représentées par hasard dans un SAS, l'estimation sera mauvaise.

Nous avons divisé la population des N communes en H strates basées sur la **Grande Zone Géographique** (le premier chiffre du code postal). Le but est alors de déterminer combien de communes n_h interroger dans chaque strate h (de sorte que $\sum n_h = n$), pour en déduire l'estimation du total suivante :

$$\hat{T}_{strat}(s) = \sum_{h=1}^H N_h \bar{y}_h \quad \text{avec} \quad \bar{y}_h = \frac{1}{n_h} \sum_{k \in s_h} y_k$$

On sait également calculer la variance d'un tel estimateur. On en déduit l'intervalle de confiance de niveau $1 - \alpha$:

$$I_{1-\alpha}^{Strat}(s) = \left[\hat{T}_{strat}(s) \pm \sqrt{\sum_{h=1}^H N_h^2 \left(\frac{1}{n_h} - \frac{1}{N_h} \right) S_{h,2023}^2} \times \Phi^{-1} \left(1 - \frac{\alpha}{2} \right) \right]$$

Là encore, les $S_{h,2023}^2$ (variance intra-strate) ont été calculés à l'aide des données de l'année 2023. Il ne manque plus qu'à choisir les n_h selon les deux approches vues en cours.

Colonnes brutes chargées : CODGEO_2024, annee, indicateur

DONNÉES PRÊTES : $N = 34980$ communes valides. Nous calculons ici les tailles d'échantillons n_h pour chaque strate selon deux méthodes :

1. **Proportionnelle** : $n_h \propto N_h$
2. **Optimale** : $n_h \propto N_h S_h$ (où S_h est l'écart-type de la strate).

6 Redressement par quotient

6.1 Mise en place

Nous disposons, dans nos données, d’une information supplémentaire jusqu’ici inexploitée : le nombre de vols violents sur l’année précédente (2023). Si on tire au sort nos n communes pour mesurer un total estimé par SAS, ce dernier peut alors être redressé de la manière suivante :

$$\hat{T}_{Red}(s) = \hat{T}_{SAS}(s) \times \frac{T_{2023}}{\hat{T}_{SAS,2023}(s)}$$

où T_{2023} est le total connu des vols en 2023 (cette valeur est, on le rappelle, de **62 633** faits), et $\hat{T}_{SAS,2023}(s)$ est le total de 2023 estimé avec les communes de l’échantillon.

De la sorte, si par malchance nous n’avons tiré au sort que des communes “calmes” qui avaient peu de vols en 2023 (et donc probablement en 2024), le coefficient de redressement ($\frac{T_{2023}}{\hat{T}_{SAS,2023}}$) sera supérieur à 1 et va réhausser l’estimation.

On fait pour cela implicitement l’hypothèse (qui paraît ici très raisonnable) que la criminalité de 2023 et celle de 2024 sont liées linéairement.

Une rapide régression linéaire (ou analyse de corrélation) donne en effet un R^2 de **NA**, ce qui est extrêmement convaincant.

À noter que pour effectuer un tel redressement, les communes de 2023 et celles de 2024 doivent être exactement les mêmes. Dans notre phase de préparation des données, nous avons effectué une jointure stricte (`inner_join`), ce qui garantit que nous travaillons uniquement sur les communes présentes et documentées sur les deux années.

6.2 Resultat

La répétition de cette expérience 1000 fois améliore sensiblement l’estimation du total. En effet, la moyenne obtenue est de **56 615** faits (très proche de la valeur $T = 54576$ théorique), et la variance est de seulement **486 836 237**.

C’est presque **14.1** fois moins que l’approche par stratification optimale ! L’information dont on dispose concernant la criminalité l’année précédente, grâce à sa très forte corrélation avec celle de cette année, mérite donc d’être prise en compte dans notre sondage.

L’approche par **pondération** (où le poids d’une commune est donné par son nombre de vols l’année précédente) peut peut-être encore améliorer la performance de notre sondage.

7 Pondération (Horvitz-Thompson)

7.1 Mise en place

Le but est ici d’augmenter la probabilité d’une commune qui subit historiquement beaucoup de vols d’être tirée au sort dans le calcul du total. Comme on dispose du nombre de faits de chaque commune sur l’année précédente (2023), on peut attribuer à chaque commune une probabilité d’être choisie proportionnelle à sa criminalité.

En d’autres termes, si on note x_k le nombre de vols de la commune k sur l’année 2023, sa probabilité d’inclusion est donnée par :

$$\pi_k = n \times \frac{x_k}{\sum_{k'=1}^N x_{k'}}$$

On fait alors le calcul pour chaque commune. Comme certaines grandes villes concentrent une part énorme de la criminalité, leurs probabilités calculées dépassent 1. On attribue une probabilité d'inclusion de 1 à toutes ces villes (c'est-à-dire qu'on les inclut **d'office** dans l'échantillon), et on les retire du tirage au sort.

Au premier calcul, on inclut d'office **22** communes. On recommence le calcul sur les restants : on trouve encore **15** communes dont la probabilité dépasse 1. On recommence le calcul sur les restants : on trouve encore **1** communes dont la probabilité dépasse 1.

Dans notre cas, on inclut donc au total **38** communes d'office. Il s'agit des zones les plus criminogènes (incluant : 75056, 13055, 69123, 75118, 31555 ...) qui représentent à elles seules **52.8** % des vols nationaux en 2024.

7.2 Resultat

En répétant l'opération 1 000 fois, on se rend compte que cette méthode marche remarquablement bien. En effet, la valeur moyenne de notre estimateur $\hat{T}_{pond}$ est de **56 821** faits, très proche du total de $T = 54576$.

Mais surtout, sa variance a été divisée par plus de **48 579** par rapport au SAS (et **13 838** par rapport à la stratification optimale) !

Grâce aux données de l'année précédente (2023), on a donc construit un estimateur de sondage qui est non-biaisé, avec une variance extrêmement faible.

7.3 Tableau Récapitulatif

Voici les performances moyennes et la variance (incertitude) de chaque méthode :

Table 1: Comparaison des Estimateurs

Methode	Moyenne	Variance	Biais_Relatif_Pct	Gain_Precision
SAS	57653	24 176 743 594	5.639	1.00
Redressement	55081	306 801 276	0.925	78.80
Strat. Prop	59253	20 695 937 952	8.570	1.17
Strat. Opt	51770	6 887 011 918	-5.141	3.51
Pondération	56821	497 677	4.114	48579.21

7.3.1 Analyse des performances de la Pondération


En répétant l'opération 1 000 fois, on constate que la pondération est extrêmement efficace. La valeur moyenne estimée est de **56 821** faits, très proche du vrai total de $T = 54576$.

Surtout, la variance a été divisée par **48 579.2** par rapport au SAS. Elle est également **13 838.3** fois plus précise que la stratification optimale !

Grâce aux données de 2023, nous avons construit un estimateur non-biaisé avec une variance minimale.

7.4 Analyse Graphique

Le graphique ci-dessous illustre la dispersion des estimateurs autour de la vraie valeur (ligne rouge). Les boîtes les plus étroites indiquent les méthodes les plus précises.



8 Conclusion

L'analyse des résultats montre clairement la hiérarchie des méthodes, similaire aux conclusions observées dans l'étude Enedis :

1. Le **SAS** présente la plus forte variance. C'est la méthode la moins précise.
2. La **Stratification** apporte un gain de précision, surtout en allocation **Optimale**, car elle réduit la variance intra-strate.
3. Le **Redressement** est très efficace grâce à la forte corrélation temporelle des données.
4. La **Pondération (Horvitz-Thompson)** est la méthode la plus performante. En sélectionnant d'office les communes les plus criminogènes, on annule la variance sur une part importante du total. L'estimation sur le reste est ensuite très précise car proportionnelle à la taille.

9 Bibliographie

Dans le cadre de cette étude, nous nous sommes appuyés sur les sources de données et références suivantes :

- **Source des données principales (Criminalité) :**
 - Service Statistique Ministériel de la Sécurité Intérieure (SSMSI). *Bases statistiques communale, départementale et régionale de la délinquance enregistrée par la police et la gendarmerie nationales*. Disponible sur data.gouv.fr : <https://www.data.gouv.fr/datasets/bases-statistiques-communale-departementale-et-regionale-de-la-delinquance-enregistree-par-la-police-et-la-gendarmerie-nationales>
- **Rapports et Contexte :**
 - Service Statistique Ministériel de la Sécurité Intérieure (SSMSI). *Rapport 2024 sur le vécu et ressenti en matière de sécurité (Enquête Genese)*. Ministère de l'Intérieur. <https://www.interieur.gouv.fr/Interstats/Actualites/Vecu-et-ressenti-en-matiere-de-securite-Victimation-delinquance-et-sentiment-d-insecurite-Rapport-d-enquete-edition-2024>