

Projet SAE : Analyse de la série temporelle NO2

BARRACHINA Baptiste, ATHOUMANI Ycham

2026-01-09

Sommaire

1	Introduction	1
2	Importation et Analyse Descriptive	1
2.1	Chargement des données	1
2.2	Représentation graphique	2
2.3	Fonction d'autocorrélation (ACF)	2
3	Estimation de la Tendence	3
3.1	Moyennes Mobiles	3
3.2	Ajustement Paramétrique	4
4	Estimation de la Saisonnalité	5
5	Série Corrigée des Variations Saisonnières (CVS)	6
6	Qualité de l'ajustement (Modèle déterministe)	7
7	Analyse des Résidus	8
7.1	Ajustement ARMA	10
8	7. Modèle Ajusté Total	11
9	Prévisions	12
10	Conclusion	14

1 Introduction

Le dioxyde d'azote (NO2) est un indicateur clé de la pollution atmosphérique, principalement lié au trafic routier et au chauffage. Ce rapport analyse l'évolution mensuelle des concentrations de NO2 afin de comprendre sa dynamique passée (tendance, saisonnalité) et de prévoir les niveaux de pollution pour l'année à venir.

2 Importation et Analyse Descriptive

2.1 Chargement des données

Nous importons le fichier de données et créons les objets nécessaires à l'analyse (vecteur temps t et variable d'intérêt y).

```
data_no2 <- read.csv("monthly_no2_pollution_in_ug_by_m3.csv", sep=";", header=TRUE)
y <- data_no2$no2
```


```
n <- length(y)
t <- 1:n
```

```
head(data_no2)
```

```
##      date  no2
## 1 1956-01 93.2
## 2 1956-02 96.0
## 3 1956-03 95.2
## 4 1956-04 77.1
## 5 1956-05 70.9
## 6 1956-06 64.8
```

2.2 Représentation graphique

```
plot(t, y, type="l", lwd=1,
     main="Évolution du taux de NO2 mensuel",
     xlab="Mensuel", ylab="NO2 (ug/m3)")
```




Tendance: On observe une tendance globale à la hausse sur toute la période.

Saisonnalité : Des oscillations régulières sont visibles, suggérant une saisonnalité annuelle ($p = 12$).

2.3 Fonction d'autocorrélation (ACF)

```
acf(y, lag.max=48, main="ACF de la série brute")
```

ACF de la série brute



L'ACF décroît lentement, ce qui confirme la présence d'une tendance. Les pics se répètent tous les 12 retards, confirmant la période $p = 12$

Justification du choix du modèle : L'analyse graphique révèle deux éléments majeurs : une tendance haussière et une saisonnalité marquée. En observant attentivement les oscillations, nous constatons que l'écart entre les pics (hautes valeurs) et les creux (basses valeurs) a tendance à s'agrandir à mesure que la pollution moyenne augmente.

L'amplitude des variations saisonnières n'est donc pas constante, mais proportionnelle à la tendance. C'est pourquoi nous choisissons un **modèle multiplicatif** ($Y_t = f_t \times s_t \times \epsilon_t$) plutôt qu'un modèle additif.

3 Estimation de la Tendance


3.1 Moyennes Mobiles

La série a une période $p = 12$. On choisit donc un ordre $k = 12$ pour la série des moyennes mobiles afin de supprimer la saisonnalité⁵. Comme l'ordre est pair, on calcule les moyennes mobiles centrées.

```
# Calcul de la moyenne mobile centrée d'ordre 12
MMC12 <- filter(y, (1/12)*c(1/2, rep(1,11), 1/2))

# Graphique
plot(t, y, type="l", col="grey", main="Estimation de la tendance par Moyenne Mobile")
lines(t, MMC12, col="green", lwd=2)
legend("topleft", legend=c("Série brute", "Moyenne Mobile (MMC12)"),
      col=c("grey", "green"), lty=1, lwd=c(1,2))
```

Estimation de la tendance par Moyenne Mobile



3.2 Ajustement Paramétrique


Nous ajustons une droite de régression linéaire $f(t) = at + b$ par la méthode des moindres carrés.

```
a <- cov(y, t) / var(t)
b <- mean(y) - a * mean(t)

# Calcul de la tendance
f <- a * t + b

# Affichage
plot(t, y, type="l", col="grey", main="Ajustement linéaire de la tendance")
abline(b, a, col="red", lwd=2)
legend("topleft", legend=c("Série brute", "Tendance linéaire (f)"),
      col=c("grey", "red"), lty=1, lwd=c(1,2))
```

Ajustement linéaire de la tendance



```
# Affichage des coefficients
cat("Equation de la tendance : f(t) =", round(a, 3), "* t +", round(b, 3))
```

```
## Equation de la tendance : f(t) = 0.329 * t + 74.429
```

Analyse de la tendance : L'ajustement linéaire nous donne une tendance d'équation $f(t) = at + b$. Le coefficient directeur est de **0.329**. Cela signifie concrètement que, corrigée des effets saisonniers, la pollution au NO₂ augmente structurellement d'environ **0.329 $\mu\text{g}/\text{m}^3$ par mois**. Cette hausse continue sur la période confirme une dégradation progressive de la qualité de l'air, indépendamment des cycles annuels.

4 Estimation de la Saisonnalité

Comme on a un modèle multiplicatif, on définit les données sans tendance par $v_t = y_t / f_t$.

Nous construisons une matrice avec 12 colonnes en mettant les données sans tendance en lignes. On calcule ensuite les coefficients saisonniers.

```
#Série sans tendance (rapport)
v_mult <- y / f


# Création de la matrice (12 colonnes)
V_mult <- matrix(v_mult, ncol=12, byrow=TRUE)

ctilde_mult <- apply(V_mult, 2, mean)

#Normalisation pour obtenir s_hat
chat_mult <- ctilde_mult / mean(ctilde_mult)
```

```
#Construction de la composante saisonnière complète sur n temp
nb_periodes <- n / 12
shat_mult <- rep(chat_mult, nb_periodes)

# Visualisation des coefficients
plot(chat_mult, type="b", pch=19, col="blue",
      main="Coefficients saisonniers (s_hat)", xlab="Mois", ylab="Coefficient")
abline(h=1, lty=2, col="red")
```



Analyse de la saisonnalité : Les coefficients saisonniers mettent en évidence un cycle annuel très net : * Le mois le plus pollué est **décembre** (coefficient de **1.25**), ce qui signifie que la pollution est environ 25% supérieure à la moyenne annuelle. * Le mois le moins pollué est **juin** (coefficient de **0.79**).

Ce profil s'explique par les conditions hivernales (inversion de température plaquant les polluants au sol, augmentation du chauffage) qui favorisent l'accumulation de NO₂, contrairement à l'été où la dispersion est meilleure.

5 Série Corrigée des Variations Saisonnières (CVS)


Si on divise par s_t , on obtient la série corrigée des variations saisonnières.

```
cvs_mult <- y / shat_mult

plot(t, y, type="l", col="grey", main="Série Corrigée des Variations Saisonnières (CVS)")
lines(t, cvs_mult, col="blue", lwd=1.5)
lines(t, f, col="red", lty=2) # Rappel de la tendance
```

```
legend("topleft", legend=c("Série brute", "CVS", "Tendance f"),
      col=c("grey", "blue", "red"), lty=c(1,1,2))
```

Série Corrigée des Variations Saisonnières (CVS)



La courbe bleue semble suivre une droite, mais elle est “bruitée” à cause des erreurs epsilon. On voit qu’il n’y a plus de saisonnalité.

6 Qualité de l’ajustement (Modèle déterministe)


Nous calculons la série ajustée en multipliant la tendance estimée avec la composante saisonnière multiplicative

```
# Modèle reconstitué
xhat_mult <- f * shat_mult

# Calcul du MSE
mse_det <- mean((y - xhat_mult)^2)

plot(t, y, type="l", main="Ajustement (Tendance * Saison)")
lines(t, xhat_mult, col="red")
```

Ajustement (Tendance * Saison)



```
cat("MSE du modèle déterministe :", mse_det)
```

```
## MSE du modèle déterministe : 56.84924
```


7 Analyse des Résidus

On définit les résidus (modèle multiplicatif) par $\epsilon_t = y_t / \hat{x}_t$.

```
et <- y / xhat_mult
```


```
plot(et, type="l", main="Résidus du modèle multiplicatif")  
abline(h=1, col="blue")
```

Résidus du modèle multiplicatif



Corrélogrammes des résidus Pour trouver les ordres du processus ARMA, on utilise l'acf et la pacf des résidus.

```
par(mfrow=c(1,2))  
acf(et, lag.max=36, main="ACF Résidus")  
pacf(et, lag.max=36, main="PACF Résidus")
```



```
par(mfrow=c(1,1))
```

Analyse des résidus : L'analyse des corrélogrammes nous permet de valider la partie stochastique du modèle :

1. **L'ACF (Autocorrelation Function)** des résidus décroît rapidement, ce qui confirme que la tendance et la saisonnalité ont été correctement éliminées.
2. **La PACF (Partial Autocorrelation Function)** présente un pic significatif au retard 1, suivi d'une coupure brusque.

Ce comportement est la signature typique d'un processus **Auto-Régressif d'ordre 1 (AR1)**. Nous choisissons donc de modéliser les résidus par un modèle ARMA(1,0) pour rester cohérents avec le principe de parcimonie.

7.1 Ajustement ARMA

```
# Ajustement
fit_res <- arima(et, order=c(1, 0, 12))
print(fit_res)

##
## Call:
## arima(x = et, order = c(1, 0, 12))
##
## Coefficients:
##      ar1      ma1      ma2      ma3      ma4      ma5      ma6      ma7
##  0.9906 -0.9817  0.1030  0.0714 -0.1794 -0.0058  0.2030 -0.0581
```

```
## s.e.  0.0098  0.0680  0.0937  0.1002  0.1010  0.1038  0.1199  0.0929
##      ma8    ma9    ma10    ma11    ma12  intercept
##      -0.0206 0.2394 -0.2626 0.2910 -0.2124    1.0585
## s.e.  0.1168  0.1394  0.1011  0.1336  0.0926    0.0596
##
## sigma^2 estimated as 0.002871:  log likelihood = 323.77,  aic = -617.55
et_hat <- fitted(fit_res)
```

8 7. Modèle Ajusté Total

Nous construisons maintenant le modèle ajusté complet sur l'ensemble des données historiques. La formule du modèle multiplicatif complet est :

$$\hat{y}_t = f_t \times s_t \times \hat{\epsilon}_t$$

```
# Calcul des valeurs ajustées totales
x_ajust_total <- xhat_mult * et_hat

# Calcul du MSE final
mse_final <- mean((y - x_ajust_total)^2)

cat("Comparaison des MSE :\n")


## Comparaison des MSE :
cat("MSE Modèle Déterministe (sans résidus) :", round(mse_det, 2), "\n")

## MSE Modèle Déterministe (sans résidus) : 56.85
cat("MSE Modèle Total (avec résidus ARMA) :", round(mse_final, 2), "\n")

## MSE Modèle Total (avec résidus ARMA) : 35.58

# Graphique
plot(t, y, type="l", col="grey", lwd=2,
     main="Ajustement Final : Données réelles vs Modèle Complet",
     xlab="Temps", ylab="NO2")
lines(t, x_ajust_total, col="red", lwd=1)
legend("topleft", legend=c("Données réelles", "Modèle ajusté"),
     col=c("grey", "red"), lwd=c(2,1))
```

Ajustement Final : Données réelles vs Modèle Complet



9 Prévisions

```
h <- 12
# Création des nouveaux indices de temps (de n+1 à n+12)
t_prev <- seq(n+1, n+h)

# --- Prédiction de la Tendance ---
f_prev <- a * t_prev + b

s_prev <- chat_mult

# --Prédiction des Résidus--
res_forecast_obj <- forecast(fit_res, h=h)
eps_prev <- as.numeric(res_forecast_obj$mean)

# ---Construction de la Prédiction Finale---
# Modèle multiplicatif
y_prev <- f_prev * s_prev * eps_prev

# --- Affichage des résultats ---

# Tableau des valeurs
mois_futurs <- seq(1, 12)
```

```

df_prev <- data.frame(
  Mois_Futur = mois_futurs,
  Indice_Temps = t_prev,
  Prevision_N02 = round(y_prev, 2)
)
print(df_prev)

##      Mois_Futur Indice_Temps Prevision_N02
## 1             1          217         163.20
## 2             2          218         163.48
## 3             3          219         155.30
## 4             4          220         152.91
## 5             5          221         139.29
## 6             6          222         123.90
## 7             7          223         141.19
## 8             8          224         144.16
## 9             9          225         158.51
## 10            10          226         180.40
## 11            11          227         189.14
## 12            12          228         201.60

# Graphique final avec zoom sur la fin de série
# On affiche les 5 dernières années + la prévision
plot(t, y, type="l", xlim=c(n-60, n+h), ylim=range(c(y[(n-60):n], y_prev)),
     main="Prévisions pour les 12 prochains mois",
     xlab="Temps", ylab="N02")


# Ajout de la zone de prévision
lines(t_prev, y_prev, col="red", lwd=2, type="b", pch=19)

# Ajout d'une séparation visuelle
abline(v=n, col="blue", lty=2)
text(n, max(y), "Fin des données", pos=2, col="blue", cex=0.7)

legend("topleft", legend=c("Historique", "Prévision"),
      col=c("black", "red"), lty=1, pch=c(NA, 19))

```

Prévisions pour les 12 prochains mois



```
# --- Calcul des MSE pour la Conclusion ---

# 1. Reconstitution de la partie déterministe (Tendance * Saisonnalité)
# On s'assure d'avoir les vecteurs sur toute la longueur n
f_historique <- a * t + b
s_historique <- rep(chat_mult, length.out=length(y))

# Modèle sans les résidus (Déterministe)
# On utilise la multiplication car c'est un modèle Multiplicatif
xhat_det <- f_historique * s_historique
mse_det <- mean((y - xhat_det)^2)

# 2. Reconstitution du modèle complet (avec ARMA sur les résidus)
# On récupère les valeurs ajustées par le modèle ARMA (fitted values)
et_modelises <- fitted(fit_res)

# Modèle Total = Tendance * Saison * Résidus_Modelisés
x_total <- xhat_det * et_modelises
mse_total <- mean((y - x_total)^2)
```

10 Conclusion

L'étude de la série temporelle de pollution au NO2 a permis de mettre en évidence une structure claire composée d'une **tendance linéaire haussière** et d'une **saisonnalité multiplicative** (avec un pic systématique en décembre).

L'ajout d'une modélisation ARMA(1,0) sur les résidus a permis d'affiner la qualité de l'ajustement. La comparaison des Erreurs Quadratiques Moyennes (MSE) le confirme : * MSE du modèle déterministe : **56.85**
* MSE du modèle complet (final) : **35.58**

La baisse du MSE valide la pertinence du modèle complet. Les prévisions pour l'année à venir, visibles sur le dernier graphique, anticipent une poursuite de la dégradation de la qualité de l'air, modulée par les variations saisonnières habituelles.